

# Intégration d'un auto-encodeur variationnel médical pré-entraîné (MedVAE) pour la segmentation multi-classes d'artères coronaires

[Auteur]

[Affiliation]

## I. INTRODUCTION

La haute résolution des images médicales est nécessaire pour préserver les détails diagnostiques, mais elle alourdit fortement le coût de calcul et de stockage des modèles d'apprentissage profond. Une réponse attractive consiste à compresser les images au moyen d'auto-encodeurs variationnels (VAE) [?] génériques pré-entraînés à grande échelle. MedVAE [?], entraîné sur plus d'un million d'images médicales, illustre cette approche : il réduit une image d'un facteur 16 (une réduction de 4 par dimension spatiale, soit une image  $512 \times 512$  ramenée à un latent  $128 \times 128$  à un seul canal) tout en cherchant à conserver les caractéristiques cliniquement pertinentes.

Cette compression reste toutefois intrinsèquement destructrice, et rien ne garantit qu'elle préserve l'information utile à toutes les tâches en aval. Les bénéfices de MedVAE ont été établis principalement sur des tâches de classification et de détection, qui reposent sur des caractéristiques globales. La segmentation fine d'artères coronaires constitue au contraire un cas défavorable. En effet, les structures à délimiter sont minces, tubulaires et peu contrastées, le nombre de classes est élevé (26 classes, à savoir le fond et 25 segments artériels) et leur distribution est fortement déséquilibrée. La question centrale que nous posons est donc la suivante : **une compression médicale avec perte préserve-t-elle suffisamment d'information anatomique pour permettre une segmentation coronarienne multi-classes ? À cette question s'en ajoute une seconde, d'ordre méthodologique : à quel endroit de la chaîne de traitement la compression doit-elle être intégrée pour que cette information demeure exploitable ?**

Pour y répondre, nous évaluons sur le jeu de données public ARCADE [?] dans quelle mesure MedVAE peut servir de représentation intermédiaire pour la segmentation. Nous comparons trois stratégies tenant compte de la compression à une référence en pleine résolution, à savoir un U-Net [?] entraîné sur les images originales : (i) segmenter directement à partir de la représentation latente compressée au moyen d'une tête de segmentation légère, (ii) adapter au préalable le compresseur au domaine coronarien par fine-tuning avant de segmenter depuis le latent, et (iii) entraîner un modèle de segmentation sur les images décompressées. Ces trois stratégies couvrent à la fois l'usage du latent et celui de l'espace pixel reconstruit,

avec et sans adaptation au domaine. Nos résultats montrent que la segmentation directe depuis le latent à un seul canal échoue, que le fine-tuning orienté reconstruction ne suffit pas à rendre ce latent exploitable, mais que l'espace pixel décompressé préserve les structures coronaires et procure même un léger gain, concentré sur les classes les plus difficiles, par rapport à la référence.

## II. MÉTHODES

### A. Données et prétraitement

Nous utilisons le jeu de données public ARCADE [?] (1 200 angiographies en niveaux de gris,  $512 \times 512$ ), dont les annotations COCO sont converties en masques denses à 26 classes. Nous adoptons une partition 80%/20% pour l'entraînement et la validation, et reportons toutes les performances sur le jeu de test officiel de 300 images. Les intensités sont normalisées dans  $[0, 1]$  et l'entraînement emploie une augmentation classique (retournements, transformations affines, ajustements de contraste et de luminosité, bruit gaussien, CLAHE) via Albumentations [?]. Les transformations géométriques sont appliquées conjointement à l'image et à son masque, afin de préserver leur alignement.

### B. Compresseur MedVAE

Le compresseur est la variante `medvae_4_1_2d` de MedVAE [?], qui réduit chaque dimension spatiale d'un facteur 4 : une image  $512 \times 512$  est encodée en un latent  $128 \times 128$  à un seul canal, soit une réduction d'un facteur 16 en surface. Sauf indication contraire, ses poids sont gelés.

### C. Conditions expérimentales

Nous comparons trois stratégies tenant compte de la compression à une référence en pleine résolution, ainsi qu'un contrôle diagnostique. Chaque condition est illustrée par son schéma de traitement.

**A (référence).** Un U-Net [?] à encodeur ResNet-34 [?] pré-entraîné sur ImageNet, entraîné de bout en bout sur les images originales (figure ).




Fig. 1. Condition A. Référence en pleine résolution : un U-Net segmente directement l'angiographie originale.

**A\* (contrôle hors distribution).** Le U-Net de la condition A, sans aucun réentraînement, est appliqué à des images d'abord encodées puis décodées par MedVAE (figure ). Cette condition isole l'effet brut de la compression en espace pixel sur un modèle non adapté, indépendamment de tout apprentissage.




Fig. 2. Condition A\*. Le U-Net gelé de A est évalué sur des images reconstruites par MedVAE, sans réentraînement.

**B (segmentation depuis le latent).** Le latent  $128 \times 128 \times 1$  produit par l'encodeur MedVAE gelé alimente une tête de segmentation légère (figure ) : une projection  $1 \times 1$  vers 128 canaux, deux blocs convolutifs entrecoupés de sur-échantillonnages bilinéaires pour revenir à  $512 \times 512$ , et une classification finale en 26 classes.




Fig. 3. Condition B. Une tête légère segmente directement le latent compressé à un seul canal de l'encodeur MedVAE pré-entraîné gelé.

**C (fine-tuning de domaine).** Identique à B, mais l'encodeur MedVAE est d'abord fine-tuné sur ARCADE par une perte de reconstruction avant d'être gelé (figure ), afin de tester si l'adaptation au domaine coronarien enrichit le latent.




Fig. 4. Condition C. Comme B, l'encodeur MedVAE étant au préalable fine-tuné sur ARCADE puis gelé.

**D (segmentation des images reconstruites).** Un U-Net identique à A est entraîné non pas sur les images originales mais sur leur version reconstruite par MedVAE (figure ). Contrairement à A\*, le réseau s'adapte ici aux artefacts de la compression.




Fig. 5. Condition D. Le U-Net est réentraîné sur les images reconstruites par MedVAE, ce qui l'adapte aux artefacts de compression.

#### D. Entraînement et évaluation

Tous les modèles minimisent une perte composite combinant à parts égales une perte de Dice et une entropie croisée :

$$\mathcal{L} = 0,5 \mathcal{L}_{\text{Dice}} + 0,5 \mathcal{L}_{\text{CE}}. \quad (1)$$

Ce choix répond directement au déséquilibre massif des classes. La perte de Dice [?] mesure le recouvrement entre prédiction et vérité terrain indépendamment de la taille des régions, ce qui empêche le fond majoritaire de dominer l'optimisation. L'entropie croisée, calculée pixel à pixel, fournit quant à elle un gradient plus stable, en particulier en début d'entraînement. L'optimisation emploie AdamW, un ordonnancement cosinus du taux d'apprentissage et la précision mixte, avec arrêt précoce sur le Dice de validation. Les performances sont rapportées par le coefficient de Dice et l'IoU, moyennés sur les 26 classes.

### III. RÉSULTATS

Le tableau résume les performances sur le test, et la figure les dynamiques d'entraînement. Des exemples de prédictions qualitatives pour chaque condition sont reportés en annexe (figures à ).




Fig. 6. Dice de validation au cours de l'entraînement. Les conditions A et D convergent vers un Dice d'environ 0,50, D dépassant légèrement A en fin de course. Les conditions B et C, qui segmentent depuis le latent compressé, restent bloquées autour de 0,04 dès les premières époques et déclenchent un arrêt précoce avant l'époch 30 : la tête n'apprend jamais, que le compresseur soit pré-entraîné (B) ou fine-tuné sur le domaine (C).

TABLE I  
PERFORMANCES SUR LE TEST ARCADE (300 IMAGES), MOYENNÉES SUR LES 26 CLASSES.

| Cond. | Modèle entraîné sur                | Dice         | IoU   |
|-------|------------------------------------|--------------|-------|
| A     | Images originales (pixel)          | 0,433        | 0,499 |
| A*    | Images reconstruites (éval. seule) | 0,434        | 0,497 |
| B     | Latent pré-entraîné                | 0,038        | 0,005 |
| C     | Latent fine-tuné                   | 0,039        | 0,000 |
| D     | Images reconstruites (pixel)       | <b>0,451</b> | 0,495 |

#### A. La segmentation depuis le latent échoue

Les conditions B et C s'effondrent à un Dice de 0,038 et 0,039, contre 0,433 pour la référence A ; la figure montre que seul le fond (C0) est correctement prédit, aucun segment artériel n'étant appris ; les prédictions sont presque entièrement assignées au fond (annexe, figures et ). Cet effondrement résulte de la conjonction de deux facteurs. D'une part, le déséquilibre des classes est extrême : le fond représente près de 95 % des pixels. Bien que la perte composite (Dice et entropie croisée) soit en partie destinée à contrer ce déséquilibre, la solution triviale consistant à tout prédire comme fond demeure un minimum local fortement attracteur dès lors que le modèle ne reçoit pas un signal d'entrée suffisamment riche ; B et C l'atteignent dès les premières époques et ne le quittent jamais (figure ). D'autre part, la tête de segmentation opère sur un latent à un seul canal et ne dispose d'aucune représentation multi-échelles : contrairement au U-Net, elle n'a ni connexions de saut ni hiérarchie de résolutions susceptibles de fournir le signal spatial fin nécessaire à la localisation de structures tubulaires minces. Ces deux facteurs se renforcent : faute de signal exploitable, la tête ne dispose d'aucun gradient utile pour s'extraire du minimum trivial. Le fine-tuning du compresseur (C) n'y change rien : optimiser MedVAE pour la reconstruction améliore la fidélité visuelle des images mais n'enrichit pas le pouvoir discriminant du latent pour la segmentation. L'IoU de C tombe d'ailleurs à 0,000, le modèle ne prédisant que le fond : l'intersection avec la vérité terrain

est nulle pour chacune des 25 classes d'artères, ce qui annule l'IoU moyen sur ces classes.

#### B. La compression en espace pixel est neutre

La condition A\* sert de contrôle : en appliquant le modèle de référence, sans réentraînement, à des images reconstruites par MedVAE, elle mesure l'effet de la seule compression, indépendamment de toute adaptation du réseau. Son Dice de 0,434 est quasi identique à celui de la référence A (0,433), et la figure montre une correspondance classe par classe quasi parfaite, les prédictions de A et A\* étant visuellement identiques (annexe, figures et ). La compression 16× préserve donc l'information anatomique exploitée par le réseau lorsqu'elle est rendue en espace pixel, au point qu'un modèle non adapté n'en souffre pas.

#### C. S'adapter à la reconstruction apporte un gain ciblé

La condition D obtient le meilleur Dice (0,451). Cette amélioration du Dice s'accompagne d'un IoU légèrement inférieur à A (0,495 contre 0,499), cohérent avec les occasionnelles sur-segmentations observées en annexe : D capture davantage de vrais positifs sur les segments rares, au prix d'un excès de faux positifs sur certains cas. L'apport propre de l'adaptation à la compression se lit le plus proprement dans l'écart entre D et A\* : ces deux conditions traitent exactement la même entrée, à savoir des images reconstruites par MedVAE, et ne diffèrent que par un point, le réseau de D ayant été réentraîné sur ces images quand celui de A\* ne l'a pas été. Leur écart,  $\Delta = 0,451 - 0,434 = +0,017$ , mesure donc le bénéfice de la seule adaptation aux artefacts de compression, sans le confondre avec l'effet de la compression elle-même (qui est nul,  $A^* \approx A$ ). Ce gain, réel mais modeste, est entièrement concentré sur les segments rares et fins que la référence ne parvenait pas à apprendre : C11 passe de 0,000 à 0,126, C18 de 0,031 à 0,113 et C19 de 0,015 à 0,191, tandis que D perd légèrement sur les grands segments (C1 : 0,789 à 0,753). Ces branches fines, absentes des prédictions de A, réapparaissent dans celles de D (annexe, figure ). Nous interprétons cet effet comme une régularisation : la reconstruction MedVAE agirait comme un débruitage qui, en atténuant la variabilité d'acquisition haute fréquence, faciliterait l'apprentissage des structures fines. Nos expériences ne permettent toutefois pas d'établir ce mécanisme directement, et cette interprétation demande à être confirmée.

## IV. DISCUSSION ET CONCLUSION

Nos expériences répondent aux deux volets de la problématique. Sur la préservation de l'information, une compression médicale avec perte de facteur 16 conserve assez d'information anatomique pour la segmentation coronarienne multi-classes, à condition de l'exploiter en espace pixel : la dégradation est nulle ( $A^* \approx A$ ) et l'adaptation à la compression apporte même un gain propre, mesuré sans confusion par l'écart contrôlé D contre A\* (+0,017), concentré sur les segments les plus difficiles. Sur le point d'intégration, le latent à un seul canal de MedVAE est en revanche inadapté à une tâche dense et




Fig. 7. Dice par classe sur le test (C0 = fond, C1 à C25 = segments coronariens). Les conditions A, A\* et D segmentent correctement les segments fréquents et épais (C1 à C7) tandis que B et C ne prédisent que le fond. Le gain de D sur A se concentre sur les segments rares et fins que A n'apprend pas (par exemple C11, C18, C19), alors que A et A\* sont quasi indiscernables, ce qui confirme que la compression en espace pixel ne dégrade pas la segmentation.

fine : la segmentation directe depuis le latent échoue, et le fine-tuning orienté reconstruction ne la débloque pas.

La principale limite tient à la variante de compression étudiée. Un latent à plusieurs canaux, ou l'exploitation des cartes intermédiaires de l'encodeur plutôt que du seul goulot d'étranglement, pourrait restaurer l'information perdue ; de même, un fine-tuning supervisé par un objectif de segmenta-

tion, plutôt que de reconstruction, est une piste naturelle. Nos résultats délimitent ainsi clairement le régime dans lequel un compresseur médical générique est utile pour la segmentation : non comme un espace latent à segmenter directement, mais comme un préprocesseur en espace pixel dont le débruitage profite aux structures les plus difficiles.

## APPENDIX A

### PRÉDICTIONS QUALITATIVES




Fig. 8. Condition A (U-Net de référence sur images originales). De gauche à droite : image d'entrée, vérité terrain, prédiction ; quatre cas de test. Les segments principaux sont bien délimités, mais les branches fines et les segments rares sont fréquemment omis.




Fig. 9. Condition A\* (U-Net de A appliqué sans réentraînement à des images reconstruites par MedVAE), un exemple représentatif. La prédiction est visuellement identique à celle de A, illustrant que la compression 16x en espace pixel préserve l'information exploitée par le réseau.




Fig. 10. Condition B (segmentation depuis le latent MedVAE pré-entraîné via une tête légère), un exemple représentatif. La prédiction est presque entièrement assignée au fond : le latent à un seul canal ne porte pas l'information nécessaire pour discriminer les segments.




Fig. 11. Condition C (identique à B, compresseur fine-tuné sur ARCADE), un exemple représentatif. L'adaptation au domaine n'apporte aucune amélioration visible ; la prédiction reste dominée par le fond.




Fig. 12. Condition D (U-Net réentraîné sur images reconstruites par MedVAE), un exemple représentatif. La délimitation des segments épais reste comparable à A et plusieurs branches fines absentes de A sont ici récupérées, au prix d'occasionnelles sur-segmentations.