

MedVAE: Adaptation, Fine-tuning and Analysis for Medical Imaging and Coronary Segmentation

Supervisor: Elsa Angelini

Yanic Rothlingshofer

Théo Palagi

Elias Corlou

Théophile Nadiedjoa

I. INTRODUCTION

II. SECTION 1: THÉOPHILE

III. ROBUSTESSE DE MEDVAE AUX DÉGRADATIONS D'ENTRÉE

MedVAE [19] est un autoencodeur perceptuel à grande échelle conçu pour compresser des images médicales en représentations latentes réduites tout en préservant les structures cliniquement pertinentes lors de la reconstruction. Le modèle a été entraîné sur plus d'un million d'images et évalué, dans son article d'origine, par PSNR et MS-SSIM ainsi que par des études de lecteurs experts. Une question reste toutefois ouverte pour un déploiement réel : *comment la qualité de reconstruction de MedVAE se comporte-t-elle lorsque l'image d'entrée n'est pas propre, mais dégradée ?* En coronarographie, cette question est loin d'être théorique : l'acquisition à faible dose induit un bruit quantique important, et les images cliniques subissent compression, flou de mouvement et artefacts variés [6].

Nous évaluons cette robustesse sur le jeu de données ARCADE [13], constitué d'angiographies coronariennes annotées. Le cadre est entièrement *full-reference* : pour chaque image nous disposons simultanément de l'image propre, d'une version dégradée de façon contrôlée, et de la reconstruction produite par MedVAE à partir de l'entrée dégradée. Cette configuration permet de tout quantifier par comparaison directe, sans recourir à une métrique de qualité sans référence. Plutôt que de chercher un unique axe de « qualité d'entrée », nous distinguons deux mesures complémentaires : l'écart entre l'image propre et l'image dégradée (l'amplitude de la dégradation appliquée) d'une part, et la fidélité de la reconstruction à son entrée dégradée d'autre part. La question de recherche devient alors : **comment la fidélité de reconstruction de MedVAE évolue-t-elle en fonction du type et de l'intensité de la dégradation appliquée en entrée ?**

Nous montrons que la réponse dépend fortement de la *nature* de la dégradation, et non seulement de son intensité. En isolant trois types de dégradation (bruit de Poisson, compression JPEG, flou gaussien), nous mettons en évidence des régimes qualitativement distincts qui révèlent le caractère passe-bas et débruiteur de MedVAE, ainsi que ses limites face aux artefacts structurés.

A. Cadre d'évaluation

1) *Pourquoi écarter les métriques sans référence* : Une première approche, naturelle, consiste à quantifier la qualité

de l'image d'entrée par une métrique *sans référence*, puis à la corrélérer à la qualité de reconstruction. Nous avons exploré cette voie avec ARNIQA [1], ainsi qu'avec un score sur mesure agrégeant des indices de netteté. Deux limites l'ont disqualifiée. D'une part, ces métriques sont calibrées sur des photos naturelles et transfèrent mal aux images de rayons X, où la notion de « haute qualité perceptuelle » n'a pas le même sens : sur les images brutes du jeu de données, la corrélation entre le score sans référence et le PSNR de reconstruction est quasi nulle, la variance de qualité intrinsèque entre images propres étant trop faible pour être exploitable. D'autre part, sous dégradation contrôlée, ces scores sont dominés par le flou et ne fournissent pas d'axe de qualité monotone, un biais cohérent avec le fait que, dans l'espace de représentation d'ARNIQA, les distorsions de flou ne forment pas de cluster séparable [1].

Or la difficulté est en réalité contournable : notre protocole est intégralement *full-reference*. Disposant de l'image propre, nous n'avons pas besoin d'estimer la qualité d'entrée « à l'aveugle », nous pouvons la *mesurer* directement par comparaison à la référence. Nous abandonnons donc l'axe sans référence et redéfinissons les deux quantités de l'étude de façon purement comparative :

- **Amplitude de dégradation** : PSNR(propre, dégradée), qui mesure de combien l'entrée s'écarte de l'image propre ;
- **Fidélité de reconstruction** : PSNR(dégradée, reconstruite), qui mesure la fidélité de MedVAE à l'entrée qu'on lui présente.

Ces deux mesures répondent à des questions distinctes et ne doivent pas être confondues : la seconde caractérise le comportement du modèle, la première sert uniquement d'abscisse contrôlée.

2) *PSNR masqué sur les vaisseaux* : Un PSNR calculé sur l'image entière est trompeur en coronarographie : le fond occupe la très grande majorité de la surface, si bien qu'un PSNR global reflète surtout la fidélité du fond et non celle des vaisseaux, la seule région cliniquement pertinente. Ce biais est tel que le PSNR global peut *augmenter* lorsque l'image se dégrade, le fond lissé devenant plus « facile » à reproduire. Nous restreignons donc le calcul aux pixels de vaisseaux, obtenus en rastérisant les annotations polygonales d'ARCADE (format COCO) en masque binaire, ce qui définit un PSNR masqué noté mPSNR. Les deux mesures ci-dessus (amplitude de dégradation et fidélité de reconstruction) sont calculées dans

cette version masquée. Le détail du calcul, l'équation et une illustration sur un exemple réel sont donnés en annexe A.

B. Méthode

1) *Protocole*: Nous utilisons l'autoencodeur medvae_4_1_2d (modalité rayons X), appliqué aux angiographies du sous-ensemble de segmentation d'ARCADE. Le prétraitement est celui fourni par MedVAE (apply_transform). Pour chaque type de dégradation, le protocole est le suivant : on tire aléatoirement 50 images propres parmi les 1000 disponibles (tirage sans remise, graine fixée pour la reproductibilité), puis on applique une rampe linéaire de 20 niveaux d'intensité croissante. À chaque niveau et pour chaque image, on calcule les deux mesures masquées mPSNR(propre, dégradée) et mPSNR(dégradée, reconstruite), moyennées sur les 50 images. Le masque de vaisseaux est commun aux deux mesures pour une image donnée. L'inférence MedVAE est intégrée à la boucle de sweep, ce qui produit la reconstruction de chaque entrée dégradée. Les effectifs volontairement modestes (50 images, 20 niveaux) sont contraints par la puissance de calcul disponible.

2) *Sweeps séparés par type de dégradation*: Conformément à l'analyse précédente, qui montrait qu'une rampe combinant plusieurs dégradations rend l'interprétation impossible, le flou écrasant les autres effets, nous menons *un sweep distinct par type de dégradation*. Cela isole l'effet propre de chaque perturbation sur la reconstruction.

C. Types de dégradation

Trois dégradations sont étudiées, chacune balayée seule :

Bruit de Poisson. Plus réaliste que le bruit gaussien pour les rayons X, où le bruit quantique (*shot noise*) domine à faible dose [6]. L'intensité est pilotée par un facteur d'échelle décroissant : plus l'échelle diminue, moins de photons sont simulés et plus le bruit est marqué.

Compression JPEG. Facteur de qualité décroissant de 95 à 5, qui introduit successivement la quantification des coefficients DCT puis les artefacts de blocs 8×8 .

Flou gaussien. Taille de noyau croissante (noyaux forcés impairs). Le niveau le plus bas, de noyau unitaire, correspond à l'image propre.

IV. RÉSULTATS ET INTERPRÉTATION

Pour chaque type de dégradation, nous traçons l'évolution des métriques en fonction du niveau d'intensité (figure 2). La courbe *amplitude de dégradation*, mPSNR(propre, dégradée), décroît par construction et sert d'abscisse contrôlée. La courbe d'intérêt est la *fidélité de reconstruction*, mPSNR(dégradée, reconstruite), qui caractérise le comportement de MedVAE. Une troisième courbe, mPSNR(propre, reconstruite), n'est tracée que pour le bruit de Poisson, où elle teste l'hypothèse de débruitage (section IV-B).

La conclusion d'ensemble est que la réponse de MedVAE ne dépend pas seulement de l'intensité de la dégradation mais de

sa *nature spectrale* : selon que la perturbation retire ou ajoute des hautes fréquences, et selon que ces hautes fréquences sont structurées ou non, la fidélité de reconstruction varie dans des directions opposées. Ce comportement est cohérent avec le biais spectral des réseaux de neurones [16] et avec le caractère passe-bas connu des autoencodeurs. Les valeurs de corrélations associées à ces observations sont synthétisées dans la table I.

TABLE I: Corrélations entre fidélité de reconstruction et amplitude de dégradation (r : Pearson, ρ : Spearman).

Dégradation	Régime	r	ρ	p -value
Flou	Global	-0,998	-0,998	$< 10^{-4}$
Poisson	Global	+0,998	+1,000	$< 10^{-4}$
JPEG	Global	+0,030	-0,439	0,90
	Avant pic	-0,990	-1,000	$< 10^{-4}$
	Après pic	+0,990	+1,000	$< 10^{-4}$

1) *Flou gaussien : anti-corrélation*: Résultat le plus marquant : quand l'entrée se dégrade, la reconstruction *s'améliore*, passant d'environ 28,9 à 39,2 dB. Les deux courbes sont quasi symétriques, et la corrélation entre fidélité et amplitude de dégradation est très fortement négative (cf. table I), avec une pente de régression de -0,84 dB par dB de dégradation.

L'explication tient au caractère passe-bas des autoencodeurs. Un VAE compresse vers un espace latent de faible dimension : il reproduit fidèlement les basses fréquences mais mal les hautes, un phénomène désigné sous le terme de biais spectral, les réseaux apprenant préférentiellement les composantes basse fréquence d'un signal [16]. Une image floutée vit déjà essentiellement dans ce sous-espace basse fréquence que MedVAE reproduit bien : elle est « facile » à reconstruire. Ce que le flou retire à l'entrée, il le rend simultanément facile à reconstruire, d'où la symétrie observée. Ce résultat confirme de façon propre et monotone le rôle particulier du flou, qui motivait l'abandon des métriques sans référence.

2) *Bruit de Poisson : corrélation positive et débruitage*: Comportement miroir du flou, et attendu : le bruit de Poisson ajoute des hautes fréquences décorrélées, précisément ce que le latent n'encode pas. L'entrée s'éloigne du propre et la reconstruction se dégrade en parallèle, les deux courbes étant quasi confondues. La corrélation est très fortement positive et la fidélité de reconstruction chute de 19,5 à 9,5 dB sur le sweep.

Le mécanisme sous-jacent est celui du débruitage par autoencodeur : le goulot latent ne peut pas représenter le bruit haute fréquence, donc il le supprime [21]. Nous le vérifions directement grâce à la troisième courbe : sur l'intégralité du sweep (100% des niveaux), la reconstruction est plus proche de l'image *propre* que de l'image *dégradée* qui lui a été présentée en entrée, soit mPSNR(propre, reconstruite) > mPSNR(dégradée, reconstruite), avec un écart moyen de +1,94 dB. La sortie de MedVAE pointe donc vers le signal et non vers le bruit : le débruitage est réel et directionnel.

Cette restauration reste toutefois partielle. Comparée non plus à l'entrée mais à l'amplitude de dégrada-




Fig. 1: Pipeline d'évaluation. Un batch d'images propres est dégradé de façon contrôlée sur N niveaux, puis reconstruit par MedVAE. Deux mesures masquées (vessel-only) sont calculées par niveau et moyennées sur le batch : $mPSNR(\text{propre}, \text{dégradée})$ quantifie l'amplitude de la dégradation appliquée, et $mPSNR(\text{dégradée}, \text{recon})$ la fidélité de reconstruction. Un sweep distinct est mené par type de dégradation (Poisson, JPEG, flou).

Évolution des métriques par niveau de dégradation (MaskedPSNR dégradée vs clean (dB))




Fig. 2: Évolution des métriques $mPSNR$ pour le bruit de Poisson, la compression JPEG et le flou gaussien. La fidélité de reconstruction (bleu) réagit différemment selon la nature de la dégradation.

tion, $mPSNR(\text{propre}, \text{reconstruite})$ demeure *en deçà* de $mPSNR(\text{propre}, \text{dégradée})$ sur les pixels de vaisseaux : passer par MedVAE ne rapproche pas l'image du propre davantage que ne le ferait l'entrée bruitée laissée telle quelle. L'erreur de reconstruction intrinsèque du modèle, liée à la compression latente avec perte, l'emporte sur le gain de débruitage dans la région cliniquement pertinente. Autrement dit, MedVAE débruite dans la bonne direction, mais ce débruitage ne suffit pas à restaurer une image diagnostiquement fidèle.

3) *Compression JPEG : deux régimes*: La compression JPEG produit une réponse *non monotone* : la fidélité de

reconstruction monte d'abord légèrement jusqu'au niveau 14 (pic à environ 26 dB), puis s'effondre. Cette non-monotonie a une conséquence statistique directe : un coefficient de corrélation calculé sur l'ensemble du sweep est trompeur. C'est une illustration du fait que les coefficients de corrélation globaux (Pearson pour la linéarité, Spearman pour la monotonie) sont aveugles aux relations non monotones et masquent ici une dynamique en deux régimes. En séparant au pic, chaque régime est au contraire presque parfaitement corrélé (table I).

Ces deux régimes correspondent à deux comportements physiques distincts. En haute et moyenne qualité, JPEG quan-

tifie les coefficients DCT et supprime les hautes fréquences : il agit comme un passe-bas par blocs, se comporte comme le flou et rend l'entrée plus « compatible » avec le latent de MedVAE, d'où la légère hausse de fidélité. En basse qualité apparaissent les artefacts de blocs 8×8 et le *ringing* autour des contours, des structures hautes fréquences *spatialement organisées* et absentes des données d'entraînement. MedVAE ne sait ni les encoder ni les ignorer proprement, d'où l'effondrement de la reconstruction. JPEG combine ainsi les deux mécanismes précédents : le régime « flou » qui aide, puis le régime « bruit structuré » qui casse la reconstruction.

A. Discussion et ouvertures

L'étude croisée de ces trois perturbations met en lumière la mécanique interne de MedVAE. Le modèle agit fondamentalement comme un filtre passe-bas intelligent et un débruiteur non linéaire : il est optimisé pour reproduire fidèlement les basses fréquences (flou gaussien) et rejeter les hautes fréquences stochastiques (bruit de Poisson). Sa limite majeure réside toutefois dans sa vulnérabilité aux hautes fréquences *structurées* hors distribution (artefacts JPEG), qu'il ne parvient ni à ignorer ni à reconstruire, corrompant ainsi l'image de sortie.

Ces caractéristiques appellent plusieurs perspectives d'évaluation clinique. En premier lieu, il conviendra de quantifier l'impact de cette dynamique passe-bas sur la détection des sténoses, tâche centrale du jeu de données ARCADE, ces pathologies constituant des structures fines particulièrement sensibles au lissage. Par ailleurs, l'exploration de l'espace latent (détaillée en section ??) révèle que MedVAE encode massivement les gradients de luminosité et de contraste. Évaluer sa robustesse face à des altérations de la dynamique des niveaux de gris (variations gamma, sous-exposition) constitue donc une prochaine étape naturelle. Enfin, le protocole gagnerait à intégrer le flou de mouvement : induit par les dynamiques cardiaques et respiratoires [18], ce flou directionnel constitue un artefact clinique omniprésent en coronarographie, dont la signature spectrale est bien plus complexe que le flou isotrope modélisé ici.

V. JEPa ADAPTATION OF MEDVAE STAGE 2

MedVAE [20] is a generalised variational autoencoder (VAE) for medical imaging, trained in two stages: the first learns faithful reconstruction, the second enriches the latent space with semantic knowledge. Medical imaging raises specific challenges — monochrome images, scarce annotations, heterogeneous modalities — that make learning robust representations particularly difficult.

A. Motivations

In its original formulation, MedVAE stage 2 aligns the latent space with BioMedCLIP representations, a foundation model pre-trained on paired medical image–text corpora. This approach has two structural limitations. First, it requires paired image–text data at inference time, which is unavailable for many clinical workflows. Second, and more fundamentally, the alignment inherits BioMedCLIP's biases and coverage gaps: coronary angiography represents a narrow and specialised sub-domain in large-scale medical vision–language pretraining, so the transmitted semantic signal may be weak or misleading. Aligning to a model that has never seen enough coronary images is unlikely to produce representations that are discriminative for vascular anatomy.

JEPa (*Joint-Embedding Predictive Architecture*) architectures [2] offer a self-supervised alternative that removes the dependency on any external model. Rather than reconstructing masked pixels — which can waste capacity on low-level texture — JEPa predicts in latent space the representations of masked regions. This forces the encoder to model the contextual relationships between visible patches and occluded areas, learning representations that are inherently structured and high-level. The approach has shown strong results across medical imaging modalities: US-JEPa [15] for ultrasound, EchoJEPa [12] for echocardiography, Brain-JEPa [7] for fMRI, and Seg-JEPa [10] for segmentation.

We propose replacing stage 2's BioMedCLIP alignment with JEPa training directly on coronary angiography images, with no dependency on an external model. The stage-1 encoder and decoder weights are kept as initialisation and the decoder remains frozen throughout, so any gain in latent structure can be evaluated independently of reconstruction quality.

B. Method

a) Original stage 2 — BioMedCLIP alignment.: In the original MedVAE formulation (Fig. 3), stage 2 fine-tunes the encoder by minimising the distance between the VAE's latent representations and BioMedCLIP embeddings for the same images. This step aims to semantically enrich the latent space by transmitting the knowledge of a pre-trained medical foundation model.

b) Modified stage 2 — JEPa adaptation.: We replace the BioMedCLIP alignment with JEPa training directly on coronary angiography images (Fig. 4). The architecture has three components, all operating in the stage-1 VAE latent space:

Med-VAE Stage 2: Preserving Clinically-Relevant Features Across Modalities




Fig. 3: Original stage 2: latent space alignment on BioMedCLIP embeddings.

- **Context encoder:** the stage-1 encoder (frozen decoder), receiving the masked image (40% of patches zeroed) and producing the context latent z_c .
- **Target encoder:** EMA copy of the context encoder with stop-gradient, encoding the full image. Weights updated as $\theta_t \leftarrow m \theta_t + (1 - m) \theta_c$ ($m = 0.996$).
- **JEPA predictor:** lightweight convolutional network (depth 3, hidden dim 128) taking z_c concatenated with a binary mask of target patches, predicting $\hat{z}_t$.




Fig. 4: Modified stage 2: JEPA adaptation — the context encoder predicts the target latent of the EMA encoder (stop-gradient).

c) *Loss function.*: The stage-2 loss is:

$$\mathcal{L}_{\text{stage2}} = \mathcal{L}_{\text{pred}} + \lambda_{\text{SIGReg}} \mathcal{L}_{\text{SIGReg}}, \quad (1)$$

where $\mathcal{L}_{\text{pred}}$ is the Smooth- L_1 loss between $\hat{z}_t$ and the channel-wise normalised target latent $\tilde{z}_t$, restricted to masked patches $\mathcal{M}$:

$$\mathcal{L}_{\text{pred}} = \frac{1}{|\mathcal{M}|} \sum_{p \in \mathcal{M}} \text{SmoothL}_1(\hat{z}_t^{(p)}, \tilde{z}_t^{(p)}), \quad (2)$$

and $\mathcal{L}_{\text{SIGReg}}$ is the SIGReg regularisation [3] on z_c , based on the Epps–Pulley statistic applied to random projections of the embeddings:

$$\mathcal{L}_{\text{SIGReg}} = \mathbb{E}_{\mathbf{v}} [T_{\text{EP}}(\{z_c^{\top} \mathbf{v}\})]. \quad (3)$$

This term prevents representational collapse without negative pairs. In practice $\lambda_{\text{SIGReg}} = 0.01$.

d) *Collapse risks.*: JEPA training is exposed to three degenerate modes. **Representational collapse** occurs when the encoder produces a constant representation that the predictor

learns to imitate — normalising $\tilde{z}_t$ channel-wise makes this solution explicitly penalised. **Dimensional collapse** corresponds to the progressive extinction of certain latent dimensions; $\mathcal{L}_{\text{SIGReg}}$ detects and corrects this by maintaining an isotropic distribution over random projections. Finally, a **too-low EMA momentum** would cause the target encoder to converge too quickly towards the context encoder, cancelling the learning signal — hence the choice of $m = 0.996$, which keeps the target encoder as a slow-moving average.

At the end of stage 2, one expects a latent space where patches that are anatomically similar produce nearby representations regardless of their spatial position. The predictor acts as a local world model: inferring a masked patch requires understanding the global structure of the image, which forces the encoder to acquire semantically informative representations rather than encoding low-level intensity patterns.

C. Results

a) *Reconstruction quality.*: During stage 2 the decoder remains frozen, so any displacement of the encoder into a subspace incompatible with the decoder directly degrades reconstruction. Table II reports metrics on 100 ARCADE validation images; Fig. 5 illustrates the effect on a representative image.

Model	MSE ($\times 10^{-3}$)	MAE	PSNR (dB)
MedVAE orig.	2.23	0.033	32.54
Stage 1	3.32	0.041	30.81
Stage 2 JEPA	82.7	0.230	16.85

TABLE II: Reconstruction on 100 ARCADE images (range $[-1, 1]$).




Fig. 5: Reconstruction on an ARCADE image: original, MedVAE, Stage 1, Stage 2 (left to right).

b) *Latent space structure.*: We measure the effective dimensionality via effective rank $\rho = \exp(-\sum_i \bar{\sigma}_i \log \bar{\sigma}_i)$, and vascular class separability via KNN-5 and a linear probe on 300 annotated ARCADE images.

Model	Eff. rank	Dims@90%	KNN-5	Lin. probe
MedVAE orig.	256.6	200	18.3 %	15.0 %
Stage 1	239.5	161	21.7 %	25.0 %
Stage 2 JEPA	164.0	25	18.3 %	21.7 %

TABLE III: Latent structure and vascular separability. Dims@90% = number of PCA components for 90% of variance.

The effective rank decreases at each stage: $256.6 \rightarrow 239.5 \rightarrow 164.0$. The most striking finding is the number of active dimensions: stage 2 concentrates 90% of its variance on only **25 dimensions** (vs. 161 for stage 1 and 200 for the original). This is characteristic of JEPA architectures — the patch-prediction objective selects a restricted but coherent subspace — and occurs without total collapse, since the effective rank remains at 164. The linear probe confirms that ARCADE adaptations bring discriminative gain over the original model (stage 1: 25.0%, stage 2: 21.7%, original: 15.0%). The slight drop from stage 1 to stage 2 suggests a trade-off: JEPA’s global contextual objective produces more concentrated representations that are slightly less linearly separable than the stage-1 features, while still outperforming the unspecialised baseline.

c) Intermediate feature visualisation — RGB PCA.

To go beyond the limitations of the 1-channel bottleneck, we analyse the feature maps of the last residual block before `conv_out` (256 channels, 64×64 resolution). We apply PCA with 3 components across these spatial vectors: $PC1 \rightarrow R$, $PC2 \rightarrow G$, $PC3 \rightarrow B$, with percentile normalisation [2%, 98%], following the visualisation protocol of DINO [5] and LeJEPA [3]. Fig. 6 reveals three distinct behaviours. The original MedVAE exhibits a pronounced border artefact — a coloured frame delimiting the image interior, reflecting a generalised pretraining that attends to image boundaries. Stage 1 produces the most spatially coherent features: the vascular trace emerges in a distinct hue from the background, suggesting that fine-tuning on ARCADE already concentrates discriminative information along the coronary tree. Stage 2 JEPA generates near-uniform large-scale features, which may seem counterintuitive but is consistent with the dimensional contraction observed in Table III: the patch-prediction objective favours a global contextual representation rather than a fine-grained local one.




Fig. 6: RGB PCA of intermediate features (before `conv_out`) for 4 coronary angiographies. Columns: original, MedVAE, Stage 1, Stage 2.

VI. MEDVAE AS A LATENT REPRESENTATION FOR CORONARY SEGMENTATION

La haute résolution des images médicales est nécessaire pour préserver les détails diagnostiques, mais elle alourdit fortement le coût de calcul et de stockage des modèles d’apprentissage profond. Une réponse attractive consiste à compresser les images au moyen d’auto-encodeurs variationnels (VAE) [9] génériques pré-entraînés à grande échelle. MedVAE [20], entraîné sur plus d’un million d’images médicales, illustre cette approche : il réduit une image d’un facteur 16 (une réduction de 4 par dimension spatiale, soit une image 512×512 ramenée à un latent 128×128 à un seul canal) tout en cherchant à conserver les caractéristiques cliniquement pertinentes.

Cette compression reste toutefois intrinsèquement destructrice, et rien ne garantit qu’elle préserve l’information utile à toutes les tâches en aval. Les bénéfices de MedVAE ont été établis principalement sur des tâches de classification et de détection, qui reposent sur des caractéristiques globales. La segmentation fine d’artères coronaires constitue au contraire un cas défavorable. En effet, les structures à délimiter sont minces, tubulaires et peu contrastées, le nombre de classes est élevé (26 classes, à savoir le fond et 25 segments artériels) et leur distribution est fortement déséquilibrée. La question centrale que nous posons est donc la suivante : **une compression médicale avec perte préserve-t-elle suffisamment d’information anatomique pour permettre une segmentation coronarienne multi-classes ? À cette question s’en ajoute une seconde, d’ordre méthodologique : à quel endroit de la chaîne de traitement la compression doit-elle être intégrée pour que cette information demeure exploitable ?**

Pour y répondre, nous évaluons sur le jeu de données public ARCADE [14] dans quelle mesure MedVAE peut servir de représentation intermédiaire pour la segmentation. Nous comparons trois stratégies tenant compte de la compression à une référence en pleine résolution, à savoir un U-Net [17] entraîné sur les images originales : (i) segmenter directement à partir de la représentation latente compressée au moyen d’une tête de segmentation légère, (ii) adapter au préalable le compresseur au domaine coronarien par fine-tuning avant de segmenter depuis le latent, et (iii) entraîner un modèle de segmentation sur les images décompressées. Ces trois stratégies couvrent à la fois l’usage du latent et celui de l’espace pixel reconstruit, avec et sans adaptation au domaine. Nos résultats montrent que la segmentation directe depuis le latent à un seul canal échoue, que le fine-tuning orienté reconstruction ne suffit pas à rendre ce latent exploitable, mais que l’espace pixel décompressé préserve les structures coronaires et procure même un léger gain, concentré sur les classes les plus difficiles, par rapport à la référence.

A. Méthodes

a) Données et prétraitement. Nous utilisons le jeu de données public ARCADE [14] (1200 angiographies en niveaux de gris, 512×512), dont les annotations COCO sont

converties en masques denses à 26 classes. Nous adoptons une partition 80 %/20 % pour l'entraînement et la validation, et reportons toutes les performances sur le jeu de test officiel de 300 images. Les intensités sont normalisées dans $[0, 1]$ et l'entraînement emploie une augmentation classique (retournements, transformations affines, ajustements de contraste et de luminosité, bruit gaussien, CLAHE) via Albumentations [4]. Les transformations géométriques sont appliquées conjointement à l'image et à son masque, afin de préserver leur alignement.

b) *Compresseur MedVAE.* Le compresseur est la variante `medvae_4_1_2d` de MedVAE [20], qui réduit chaque dimension spatiale d'un facteur 4 : une image 512×512 est encodée en un latent 128×128 à un seul canal, soit une réduction d'un facteur 16 en surface. Sauf indication contraire, ses poids sont gelés.

c) *Conditions expérimentales.* Nous comparons trois stratégies tenant compte de la compression à une référence en pleine résolution, ainsi qu'un contrôle diagnostique. Chaque condition est illustrée par son schéma de traitement.

A (référence). Un U-Net [17] à encodeur ResNet-34 [8] pré-entraîné sur ImageNet, entraîné de bout en bout sur les images originales (Fig. 7).




Fig. 7: Condition A. Référence en pleine résolution : un U-Net segmente directement l'angiographie originale.

A* (contrôle hors distribution). Le U-Net de la condition A, sans aucun réentraînement, est appliqué à des images d'abord encodées puis décodées par MedVAE (Fig. 8). Cette condition isole l'effet brut de la compression en espace pixel sur un modèle non adapté, indépendamment de tout apprentissage.




Fig. 8: Condition A*. Le U-Net gelé de A est évalué sur des images reconstruites par MedVAE, sans réentraînement.

B (segmentation depuis le latent). Le latent $128 \times 128 \times 1$ produit par l'encodeur MedVAE gelé alimente une tête de

segmentation légère (Fig. 9) : une projection 1×1 vers 128 canaux, deux blocs convolutifs entrecoupés de sur-échantillonnages bilinéaires pour revenir à 512×512 , et une classification finale en 26 classes.




Fig. 9: Condition B. Une tête légère segmente directement le latent compressé à un seul canal de l'encodeur MedVAE pré-entraîné gelé.

C (fine-tuning de domaine). Identique à B, mais l'encodeur MedVAE est d'abord fine-tuné sur ARCADE par une perte de reconstruction avant d'être gelé (Fig. 10), afin de tester si l'adaptation au domaine coronarien enrichit le latent.




Fig. 10: Condition C. Comme B, l'encodeur MedVAE étant au préalable fine-tuné sur ARCADE puis gelé.

D (segmentation des images reconstruites). Un U-Net identique à A est entraîné non pas sur les images originales mais sur leur version reconstruite par MedVAE (Fig. 11). Contrairement à A*, le réseau s'adapte ici aux artefacts de la compression.




Fig. 11: Condition D. Le U-Net est réentraîné sur les images reconstruites par MedVAE, ce qui l'adapte aux artefacts de compression.

d) *Entraînement et évaluation.* Tous les modèles minimisent une perte composite combinant à parts égales une perte de Dice et une entropie croisée :

$$\mathcal{L} = 0,5 \mathcal{L}_{\text{Dice}} + 0,5 \mathcal{L}_{\text{CE}}. \quad (4)$$




Fig. 12: Dice de validation au cours de l’entraînement. Les conditions A et D convergent vers un Dice d’environ 0,50, D dépassant légèrement A en fin de course. Les conditions B et C, qui segmentent depuis le latent compressé, restent bloquées autour de 0,04 dès les premières epochs et déclenchent un arrêt précoce avant l’epoch 30 : la tête n’apprend jamais, que le compresseur soit pré-entraîné (B) ou fine-tuné sur le domaine (C).

Ce choix répond directement au déséquilibre massif des classes. La perte de Dice [11] mesure le recouvrement entre prédiction et vérité terrain indépendamment de la taille des régions, ce qui empêche le fond majoritaire de dominer l’optimisation. L’entropie croisée, calculée pixel à pixel, fournit quant à elle un gradient plus stable, en particulier en début d’entraînement. L’optimisation emploie AdamW, un ordonnancement cosinus du taux d’apprentissage et la précision mixte, avec arrêt précoce sur le Dice de validation. Les performances sont rapportées par le coefficient de Dice et l’IoU, moyennés sur les 26 classes.

B. Résultats

Le tableau IV résume les performances sur le test, et la figure 12 les dynamiques d’entraînement. Des exemples de prédictions qualitatives pour chaque condition sont reportés en annexe (figures 14 à 18).

TABLE IV: Performances sur le test ARCADE (300 images), moyennées sur les 26 classes.

Cond.	Modèle entraîné sur	Dice	IoU
A	Images originales (pixel)	0,433	0,499
A*	Images reconstruites (éval. seule)	0,434	0,497
B	Latent pré-entraîné	0,038	0,005
C	Latent fine-tuné	0,039	0,000
D	Images reconstruites (pixel)	0,451	0,495

a) *La segmentation depuis le latent échoue.* : Les conditions B et C s’effondrent à un Dice de 0,038 et 0,039, contre 0,433 pour la référence A ; la figure 13 montre que seul le fond (C0) est correctement prédit, aucun segment artériel n’étant appris ; les prédictions sont presque entièrement assignées au fond (figures 16 et 17). Cet effondrement résulte de la conjonction de deux facteurs. D’une part, le déséquilibre des classes est extrême : le fond représente près de 95 % des pixels.

Bien que la perte composite (Dice et entropie croisée) soit en partie destinée à contrer ce déséquilibre, la solution triviale consistant à tout prédire comme fond demeure un minimum local fortement attracteur dès lors que le modèle ne reçoit pas un signal d’entrée suffisamment riche ; B et C l’atteignent dès les premières epochs et ne le quittent jamais (figure 12). D’autre part, la tête de segmentation opère sur un latent à un seul canal et ne dispose d’aucune représentation multi-échelles : contrairement au U-Net, elle n’a ni connexions de saut ni hiérarchie de résolutions susceptibles de fournir le signal spatial fin nécessaire à la localisation de structures tubulaires minces. Ces deux facteurs se renforcent : faute de signal exploitable, la tête ne dispose d’aucun gradient utile pour s’extraire du minimum trivial. Le fine-tuning du compresseur (C) n’y change rien : optimiser MedVAE pour la reconstruction améliore la fidélité visuelle des images mais n’enrichit pas le pouvoir discriminant du latent pour la segmentation. L’IoU de C tombe d’ailleurs à 0,000, le modèle ne prédisant que le fond : l’intersection avec la vérité terrain est nulle pour chacune des 25 classes d’artères, ce qui annule l’IoU moyen sur ces classes.

b) *La compression en espace pixel est neutre.* : La condition A* sert de contrôle : en appliquant le modèle de référence, sans réentraînement, à des images reconstruites par MedVAE, elle mesure l’effet de la seule compression, indépendamment de toute adaptation du réseau. Son Dice de 0,434 est quasi identique à celui de la référence A (0,433), et la figure 13 montre une correspondance classe par classe quasi parfaite, les prédictions de A et A* étant visuellement identiques (figures 14 et 15). La compression 16× préserve donc l’information anatomique exploitée par le réseau lorsqu’elle est rendue en espace pixel, au point qu’un modèle non adapté n’en souffre pas.

c) *S’adapter à la reconstruction apporte un gain ciblé.* : La condition D obtient le meilleur Dice (0,451). Cette amélioration du Dice s’accompagne d’un IoU légèrement inférieur à A (0,495 contre 0,499), cohérent avec les occasionnelles sur-segmentations observées en annexe : D capture davantage de vrais positifs sur les segments rares, au prix d’un excès de faux positifs sur certains cas. L’apport propre de l’adaptation à la compression se lit le plus proprement dans l’écart entre D et A* : ces deux conditions traitent exactement la même entrée, à savoir des images reconstruites par MedVAE, et ne diffèrent que par un point, le réseau de D ayant été réentraîné sur ces images quand celui de A* ne l’a pas été. Leur écart, $\Delta = 0,451 - 0,434 = +0,017$, mesure donc le bénéfice de la seule adaptation aux artefacts de compression, sans le confondre avec l’effet de la compression elle-même (qui est nul, $A^* \approx A$). Ce gain, réel mais modeste, est entièrement concentré sur les segments rares et fins que la référence ne parvenait pas à apprendre : C11 passe de 0,000 à 0,126, C18 de 0,031 à 0,113 et C19 de 0,015 à 0,191, tandis que D perd légèrement sur les grands segments (C1 : 0,789 à 0,753). Ces branches fines, absentes des prédictions de A, réapparaissent dans celles de D (figure 18). Nous interprétons cet effet comme une régularisation : la reconstruction MedVAE




Fig. 13: Dice par classe sur le test (C0 = fond, C1 à C25 = segments coronariens). Les conditions A, A* et D segmentent correctement les segments fréquents et épais (C1 à C7) tandis que B et C ne prédisent que le fond. Le gain de D sur A se concentre sur les segments rares et fins que A n’apprend pas (par exemple C11, C18, C19), alors que A et A* sont quasi indiscernables, ce qui confirme que la compression en espace pixel ne dégrade pas la segmentation.

agirait comme un débruitage qui, en atténuant la variabilité d’acquisition haute fréquence, faciliterait l’apprentissage des structures fines. Nos expériences ne permettent toutefois pas d’établir ce mécanisme directement, et cette interprétation demande à être confirmée.

C. Discussion

Nos expériences répondent aux deux volets de la problématique. Sur la préservation de l’information, une compression médicale avec perte de facteur 16 conserve assez d’information anatomique pour la segmentation coronarienne multi-classes, à condition de l’exploiter en espace pixel : la dégradation est nulle ($A^* \approx A$) et l’adaptation à la compression apporte même un gain propre, mesuré sans confusion par l’écart contrôlé D contre A* (+0,017), concentré sur les segments les plus difficiles. Sur le point d’intégration, le latent à un seul canal de MedVAE est en revanche inadapté à une tâche dense et fine : la segmentation directe depuis le latent échoue, et le fine-tuning orienté reconstruction ne la débloque pas.

La principale limite tient à la variante de compression étudiée. Un latent à plusieurs canaux, ou l’exploitation des cartes intermédiaires de l’encodeur plutôt que du seul goulot d’étranglement, pourrait restaurer l’information perdue ; de même, un fine-tuning supervisé par un objectif de segmentation, plutôt que de reconstruction, est une piste naturelle. Nos résultats délimitent ainsi clairement le régime dans lequel un compresseur médical générique est utile pour la segmentation : non comme un espace latent à segmenter directement, mais comme un préprocesseur en espace pixel dont le débruitage profite aux structures les plus difficiles.

VII. CONCLUSION

REFERENCES

- [1] Lorenzo Agnolucci, Leonardo Galteri, Marco Bertini, and Alberto Del Bimbo. ARNIQA: Learning distortion manifold for image quality assessment. In *IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2024.
- [2] Mahmoud Assran, Quentin Duval, Ishan Misra, Piotr Bojanowski, Pascal Vincent, Michael Rabbat, Yann LeCun, and Nicolas Ballas. Self-supervised learning from images with a joint-embedding predictive architecture, 2023.
- [3] Randall Balestriero and Yann LeCun. Lejpa: Provable and scalable self-supervised learning without the heuristics, 2025.
- [4] Alexander Buslaev, Vladimir I. Iglovikov, Eugene Khvedchenya, Alex Parinov, Mikhail Druzhinin, and Alexandr A. Kalinin. Albumentations: Fast and flexible image augmentations. *Information*, 11(2):125, 2020.
- [5] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021.
- [6] Mario Cesarelli, Paolo Bifulco, Tavis Cerciello, Maria Romano, and Luca Paura. X-ray fluoroscopy noise modeling for filter design. *International Journal of Computer Assisted Radiology and Surgery*, 8:269–278, 2013.
- [7] Zijian Dong, Ruilin Li, Yilei Wu, Thuan Tinh Nguyen, Joanna Su Xian Chong, Fang Ji, Nathanael Ren Jie Tong, Christopher Li Hsian Chen, and Juan Helen Zhou. Brain-jepa: Brain dynamics foundation model with gradient positioning and spatiotemporal masking. In *Advances in Neural Information Processing Systems*, volume 37, pages 86048–86073. Curran Associates, Inc., 2024.
- [8] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *CVPR*, pages 770–778, 2016.
- [9] Diederik P. Kingma and Max Welling. Auto-encoding variational bayes. In *ICLR*, 2014.
- [10] Khoa Dang Dang Le, Nguyen Nhu Son, Giang Long Nguyen, and Hiep Xuan Huynh. Seg-jepa: Joint-embedding predictive architecture for self-supervised medical image segmentation. In Ngoc Thanh Nguyen, Chun-Hao Chen, Hamido Fujita, Tzung-Pei Hong, Yannis Manolopoulos, and Krystian Wojtkiewicz, editors, *Recent Challenges in Intelligent Information and Database Systems*, pages 86–101. Springer Nature Singapore, 2026.
- [11] Fausto Milletari, Nassir Navab, and Seyed-Ahmad Ahmadi. V-Net: Fully convolutional neural networks for volumetric medical image segmentation. In *3DV*, pages 565–571, 2016.
- [12] Alif Munim, Adibvafa Fallahpour, Teodora Szasz, Ahmadreza Attarpour, River Jiang, Brana Sooriyanathan, Maala Sooriyanathan, Heather Whitney, Jeremy Slivnick, Barry Rubin, Wendy Tsang, and Bo Wang. Echojpa: A latent predictive foundation model for echocardiography, 2026.

- [13] Maxim Popov, Akmaral Amanturdieva, Nuren Zhaksylyk, et al. Dataset for automatic region-based coronary artery disease diagnostics using x-ray angiography images. *Scientific Data*, 11:20, 2023.
- [14] Maxim Popov, Akmaral Amanturdieva, Nuren Zhaksylyk, et al. Dataset for automatic region-based coronary artery disease diagnostics using x-ray angiography images. *Scientific Data*, 11:20, 2024.
- [15] Ashwath Radhachandran, Vedrana Ivezić, Shreeram Athreya, Ronit Anilkumar, Corey W. Arnold, and William Speier. Us-jepa: A joint embedding predictive architecture for medical ultrasound, 2026.
- [16] Nasim Rahaman, Aristide Baratin, Devansh Arpit, Felix Draxler, Min Lin, Fred A. Hamprecht, Yoshua Bengio, and Aaron Courville. On the spectral bias of neural networks. In *Proceedings of the 36th International Conference on Machine Learning (ICML)*, volume 97 of *PMLR*, pages 5301–5310, 2019.
- [17] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *MICCAI*, pages 234–241, 2015.
- [18] Eric J. Topol and Steven E. Nissen. Our preoccupation with coronary luminology: The illusion of spurious absolute measures. *Circulation*, 92(8):2333–2342, 1995.
- [19] Maya Varma, Ashwin Kumar, Rogier van der Sluijs, Sophie Ostmeier, Louis Blankemeier, Pierre Chambon, Christian Bluethgen, Jip Prince, Curtis Langlotz, and Akshay Chaudhari. Medvae: Efficient automated interpretation of medical images with large-scale generalizable autoencoders, 2025.
- [20] Maya Varma, Ashwin Kumar, Rogier van der Sluijs, Sophie Ostmeier, Louis Blankemeier, Pierre Chambon, Christian Bluethgen, Jip Prince, Curtis Langlotz, and Akshay Chaudhari. Medvae: Efficient automated interpretation of medical images with large-scale generalizable autoencoders, 2025.
- [21] Pascal Vincent, Hugo Larochelle, Yoshua Bengio, and Pierre-Antoine Manzagol. Extracting and composing robust features with denoising autoencoders. In *Proceedings of the 25th International Conference on Machine Learning (ICML)*, pages 1096–1103, 2008.

APPENDIX




Fig. 14: Condition A (U-Net de référence sur images originales). De gauche à droite : image d'entrée, vérité terrain, prédiction ; quatre cas de test. Les segments principaux sont bien délimités, mais les branches fines et les segments rares sont fréquemment omis.




Fig. 15: Condition A* (U-Net de A appliqué sans réentraînement à des images reconstituées par MedVAE), un exemple représentatif. La prédiction est visuellement identique à celle de A, illustrant que la compression 16× en espace pixel préserve l'information exploitée par le réseau.




Fig. 16: Condition B (segmentation depuis le latent MedVAE pré-entraîné via une tête légère), un exemple représentatif. La prédiction est presque entièrement assignée au fond : le latent à un seul canal ne porte pas l'information nécessaire pour discriminer les segments.




Fig. 17: Condition C (identique à B, compresseur fine-tuné sur ARCADE), un exemple représentatif. L'adaptation au domaine n'apporte aucune amélioration visible ; la prédiction reste dominée par le fond.




Fig. 18: Condition D (U-Net réentraîné sur images reconstituées par MedVAE), un exemple représentatif. La délimitation des segments épais reste comparable à A et plusieurs branches fines absentes de A sont ici récupérées, au prix d'occasionnelles sur-segmentations.

Le PSNR masqué (mPSNR) restreint le calcul de l'erreur aux seuls vaisseaux afin d'écarter le biais du fond, largement majoritaire et cliniquement non pertinent. Les annotations polygonales d'ARCADE sont rastérisées en masque binaire (`cv2.fillPoly`), puis redimensionnées par interpolation au plus proche voisin pour préserver leur binarité. L'erreur quadratique moyenne n'est évaluée que sur cet ensemble de pixels, noté $\mathcal{M}$:

$$\text{mPSNR}(x, y) = 10 \log_{10} \frac{D^2}{\frac{1}{|\mathcal{M}|} \sum_{p \in \mathcal{M}} (x_p - y_p)^2}, \quad (5)$$

où D est la dynamique des intensités ($D = 1$ pour des images normalisées dans $[0, 1]$).




Fig. 19: Principe du PSNR masqué sur un exemple réel d'ARCADE. L'image propre et sa version dégradée partagent le même masque de vaisseaux $\mathcal{M}$ (rouge). L'erreur n'est évaluée que sur ces pixels ($\approx 2\%$ de la surface).

Visualisation des dégradations synthétiques




Fig. 20: Visualisation des dégradations synthétiques appliquées en entrée (détail). De gauche à droite : image propre (*Clean*), bruit de Poisson, compression JPEG, flou gaussien. L'intensité de la dégradation augmente de haut en bas, faisant apparaître l'injection de hautes fréquences (bruit, blocs 8×8) ou au contraire leur suppression (lissage passe-bas).