

# MedVAE : adaptation, fine-tuning et analyse pour l'imagerie médicale et la segmentation coronaire

Yanic Rothlingshofer   Théo Palagi   Elias Corlou   Théophile Nadiedjoa

*Télécom Paris*

Encadrant : Elsa Angelini



**Contexte.** L'apprentissage profond en imagerie médicale est limité par la haute résolution nécessaire au détail diagnostique. Les VAE compressent l'image en un latent compact.

- **MedVAE** : compresseur médical générique ( $> 1\text{M}$  images),  $\times 16$  ( $512^2 \rightarrow 128^2 \times 1$ ), entraîné en deux étapes (reconstruction puis enrichissement sémantique).

**Domaine.** Angiographie coronaire (ARCADE, 1 200 images) : structures fines, tubulaires, peu contrastées, bruit et artefacts.

## Question centrale

Un compresseur médical générique reste-t-il **fiable et utile** face à un domaine clinique spécifique et exigeant ?

## Quatre axes complémentaires :

- 1 Robustesse aux dégradations
- 2 Biais inductif de qualité via FiLM
- 3 Structuration sémantique du latent (JEPA)
- 4 Représentation latente pour la segmentation

## Robustesse de MedVAE aux dégradations


À compléter avec le contenu d'Elias.

Figures déjà disponibles dans `figures/elias/` : `degradation_visual.png`, `pipeline.pdf`, `mpsnr.pdf`, `metrics_by_level_*`.


## Biais inductif de qualité d'image (FiLM)

- MedVAE applies the **same transform** to a clean or a heavily degraded coronary angiography: no notion of *how degraded* the input is.
- **Hypothesis:** conditioning MedVAE on a quality score  $c \in [0, 1]$ , injected via FiLM, should let it adapt to the degradation level actually present.
- Three independent ways to compute  $c$  (A: weighted, B: PCA, C: learned)  $\rightarrow$  run the *same* pipeline three times.

# Building the quality score $c$




# Does the score make clinical sense?




ARCADE images sorted by increasing score  $c$  (approach A).

# FiLM conditioning & training




# Result: conditioning hurts reconstruction



● Baseline > cVAE on **all 3 approaches** × **all 4 metrics** (MSE, SSIM, PSNR, HaarPSI), even masked

# Ablation: does the network actually use $c$ ?


Per-image difference: cVAE(real  $c$ ) vs cVAE( $c=0.5$ ) — Approach C




Real  $c$  vs. constant  $c=0.5$  (approach C): gap grows with image quality: the network's response genuinely depends on  $c$ .

# Structuration sémantique de l'espace latent (JEPA)

## Med-VAE Stage 2: Preserving Clinically-Relevant Features Across Modalities




# Stage 2 modifié — adaptation JEPA



$$\mathcal{L}_{\text{stage2}} = \mathcal{L}_{\text{pred}} + \lambda_{\text{SIGReg}} \mathcal{L}_{\text{SIGReg}}$$


$$\mathcal{L}_{\text{pred}} = \frac{1}{|\mathcal{M}|} \sum_{p \in \mathcal{M}} \text{SmoothL}_1 \left( \hat{z}_t^{(p)}, \tilde{z}_t^{(p)} \right), \quad \mathcal{L}_{\text{SIGReg}} = \mathbb{E}_{\mathbf{v}} \left[ T_{\text{EP}} \left( \{z_c^{\top} \mathbf{v}\} \right) \right]$$

# Résultats — reconstruction



- Décodeur **gelé** : tout déplacement de l'encodeur dégrade le PSNR (16.85 dB pour le stage 2).
- Le stage 2 JEPA **floute** : prédire un patch masqué revient à *moyenner* les zones plausibles  $\Rightarrow$  perte des hautes fréquences (vaisseaux fins).
- Cohérent avec l'objectif latent : on optimise la sémantique, pas la fidélité pixel.

# Résultats — PCA RGB des features intermédiaires



## Intégration pour la segmentation multi-classes

**Tâche.** Segmentation fine des artères coronaires sur ARCADE :

- 26 classes (le fond et 25 segments)
- structures minces, tubulaires, peu contrastées
- déséquilibre extrême ( $\approx 95\%$  de fond)

**Outil.** MedVAE, auto-encodeur variationnel médical pré-entraîné : compression  $\times 16$  ( $512^2 \rightarrow 128^2 \times 1$ ), mais **avec perte**.

## Deux questions


- 1 La compression préserve-t-elle assez d'information anatomique pour la segmentation ?
- 2 Où l'intégrer : espace **latent** ou espace **pixel** ?

# Méthode : cinq conditions


- **A** — U-Net pleine résolution (référence)
- **A\*** — U-Net de A sur images reconstruites, **sans réentraînement** (contrôle)
- **B** — tête légère sur le latent gelé
- **C** — comme B, encodeur fine-tuné sur ARCADE
- **D** — U-Net réentraîné sur images reconstruites

Espace latent : B, C ; espace pixel : A\*, D.

## Condition B — MedVAE pré-entraîné (gelé) + tête de segmentation



## Condition D — U-Net entraîné sur images reconstruites par MedVAE




# Résultat 1 : la segmentation depuis le latent échoue

- B et C : Dice  $\approx 0,04$  (contre 0,433 pour A)
- seul le fond est prédit, IoU  $\rightarrow 0$

## Pourquoi ?

- déséquilibre 95 % de fond  $\Rightarrow$  minimum trivial très attracteur
- latent à 1 canal, aucune caractéristique multi-échelles (ni connexions de saut)

Le fine-tuning du compresseur (C) n'y change rien.



## Résultat 2 : l'espace pixel préserve, l'adaptation aide

| Cond. | Dice         | IoU   |
|-------|--------------|-------|
| A     | 0,433        | 0,499 |
| A*    | 0,434        | 0,497 |
| B     | 0,038        | 0,005 |
| C     | 0,039        | 0,000 |
| D     | <b>0,451</b> | 0,495 |

- **Compression neutre** :  $A^* \approx A$  (0,434 vs 0,433)
- **Résultat central** :  $D - A^* = +0,017$   
gain propre de l'adaptation (même entrée, seul le réentraînement diffère)
- gain concentré sur les segments rares et fins (C11, C18, C19)




# Prédictions qualitatives





## Espace pixel : structures bien segmentées.

Condition A\* — U-Net A sur images MedVAE reconstituées

Image originale



Masque prédit (A\*)



## Espace latent : tout est prédit comme fond.

Visualisation des segmentations — condition\_b\_medvae

Image originale



Masque prédit







Image originale



## Vers un *foundation model* pour l'imagerie médicale par rayonnement

Unifier les axes explorés en un objectif d'entraînement unique.

- **Objectif hybride JEPA + reconstruction** : prédire les patches latents masqués tout en gardant l'encodeur ancré à un espace décodable.
- **Dégradations physiquement fondées** : bruit quantique, contraste/luminosité, champs multiplicatifs, flou de mouvement anisotrope (cardiaque/respiratoire).
- **Conditionnement (CVAE)** sur les métadonnées DICOM (modalité, dose, SNR, qualité)  
→ représentations désenchevêtrées contenu / qualité d'acquisition.
- **Validation downstream** : classification, détection, segmentation multi-modalités (ARCADE comme banc d'essai exigeant).

# Conclusion générale

Sur quatre axes complémentaires, nous avons sondé le comportement de MedVAE, compresseur médical générique, sur le domaine exigeant de l'angiographie coronaire :

- **Robustesse** : filtre passe-bas intelligent et débruiteur non linéaire ; s'effondre sur les hautes fréquences *structurées* (artefacts JPEG) — la nature de la dégradation prime sur son intensité.
- **FiLM** : conditionner sur un score de qualité dégrade légèrement la reconstruction (compromis architectural), bien que le réseau exploite réellement le signal.
- **JEPA** : latent nettement plus compact (90% de variance sur 25 dimensions), gain discriminatif, mais coût en reconstruction (décodeur gelé).
- **Segmentation** : la compression  $\times 16$  préserve l'anatomie **en espace pixel** (gain ciblé sur les vaisseaux fins) ; le latent à un canal reste inadapté à la prédiction dense directe.

**Bilan.** Compression fidèle réutilisable en espace pixel, mais latent pas encore assez *organisé sémantiquement* ni *conscient de l'acquisition* pour être segmenté ou conditionné directement.